


🔧 ¿Qué es la Ingeniería de Datos?



📄 Definición

Diseño, construcción y mantenimiento de sistemas para manejar **grandes volúmenes de datos**

🔗 En Palabras Simples

El ingeniero de datos prepara las '**tuberías**' que hacen fluir los datos desde múltiples fuentes hasta llegar **organizados y listos para usar**

🎯 Resultado Final

Datos **confiables, escalables y accesibles** para análisis, IA y decisiones de negocio

Funciones Principales del Ingeniero de Datos



Optimización

Performance y
calidad

Queries • Costos •
Disponibilidad



Ingesta

Conectar múltiples
fuentes de datos

APIs • Bases de datos •
Sensores • Logs



Procesamiento

Limpiar y transformar
datos

ETL/ELT • Validación •
Normalización



Automatización

Pipelines confiables y
repetibles

Scheduling • Monitoreo •
Alertas



Ingeniero de Datos

Arquitecto de Flujos



Almacenamiento


Diseñar warehouses y
lakes

Escalabilidad • Seguridad •
Optimización

Hacer que los datos estén listos para usar, de forma confiable y escalable

¿Qué es un Pipeline de Datos?

AUTOMATED DATA PIPELINE



Definición

Proceso **automatizado** que mueve datos desde la fuente hasta el destino, aplicando **limpieza y transformaciones**

Características

↻ Automatizado

🔧 Transformaciones

→ Flujo continuo

✅ Confiable


¿Por qué Pipeline?

- Elimina trabajo manual repetitivo
- Garantiza calidad consistente
- Permite escalabilidad automática
- Facilita monitoreo y alertas

Flujo Típico de un Pipeline de Datos



Modos de Procesamiento



Cada etapa puede tener diferentes productos y tecnologías según necesidades.



ETL vs ELT

Dos Enfoques para Procesar Datos

ETL

Extract → Transform → Load

Procesa **ANTES** de guardar

1  Extraer



2  Transformar



3  Cargar

Solo guarda datos limpios

ETL - Beneficios

- ✓ Control de calidad previo
- ✓ Storage optimizado
- ✓ Warehouses tradicionales



Depende de tu infraestructura y necesidades

En GCP: **ELT es preferido** por BigQuery, pero ETL sigue siendo válido

ELT

Extract → Load → Transform

Procesa **DESPUÉS** de guardar

1  Extraer



2  Cargar



3  Transformar

Guarda datos crudos completos

ELT - Beneficios

- ✓ Datos crudos preservados
- ✓ Escalabilidad cloud
- ✓ Warehouses modernos

🔍 Cuándo usar ETL

Extract → Transform → Load

Casos de Uso Ideales

🛡️ Control de Calidad Estricto

Necesitas validar y limpiar antes de almacenar

🗑️ Storage Limitado

Evitas llenar tu almacenamiento con datos basura

🗄️ Warehouses Tradicionales

Oracle, SQL Server, Teradata no procesan volúmenes masivos

⚡ Transformaciones Pesadas

Lógica compleja mejor fuera del warehouse

Stack ETL Típico

↓ Ingesta

Talend

Informatica

Apache Airflow

⚙️ Procesamiento

Apache Spark

Python Scripts

SSIS

🗄️ Almacenamiento

SQL Server

Oracle DW

Teradata

📊 Visualización

Power BI

Tableau

QlikSense

ETL: Ideal cuando necesitas control previo y trabajas con infraestructura tradicional

Garantiza que solo datos de calidad lleguen al warehouse



Cuándo usar ELT

Extract → Load → Transform

Casos de Uso Modernos



Warehouses en la Nube

BigQuery, Snowflake procesan petabytes internamente.



Preservar Datos Crudos

Para auditorías, compliance y re-procesamientos.



Escalabilidad Automática

Aprovecha compute elástico del cloud.



Data Lake/Lakehouse

Guardar primero, procesar según necesidad.

Stack ELT en GCP



Ingesta

Kafka

Fivetran

Airbyte

Pub/Sub



Almacenamiento

Cloud Storage

BigLake

BigQuery



Procesamiento

SQL

Dbt

Stored Procedures

Dataflow



Visualización


Looker Studio

Connected Sheets

Looker

ELT en GCP: Potencia de BigQuery para procesamiento masivo, escalable y costo-optimizado.

Ingesta de Datos - Fuentes y Modos



Modos de Ingesta



La elección del modo depende de latencia requerida y volumen de datos

Servicios GCP para Ingesta de Datos

Google Cloud Platform



Cloud Storage (GCS)

Data Lake y Landing Zone

- Ingesta de archivos (batch/eventos)
- Múltiples clases de almacenamiento

Uso: CSV, JSON, logs, backups



Pub/Sub

Streaming & Event Messaging

- Mensajería en tiempo real y baja latencia
- Patrones de desacoplamiento (fan-out)

Uso: IoT, eventos en vivo, microservicios



Datastream

Change Data Capture (CDC)

- Captura de Cambios (CDC) de BBDD
- Replicación con bajo impacto

Uso: Replicación de BBDD, analítica real-time



Cloud Functions

Event-driven Ingestion

- Procesamiento serverless basado en eventos
- Auto-escalado y sin gestión de infraestructura

Uso: APIs, procesamiento de archivos, webhooks




BigQuery DTS

Managed SaaS Connectors

- Conectores para SaaS y apps de Google Transferencias
- de datos gestionadas y programadas

Uso: Datos de Marketing, apps SaaS



Storage Transfer

Large Scale Data Movement

- Movimiento de datos a gran escala
- Migraciones on-premise y multi-cloud

Uso: Migraciones, sincronización de backups

Todos los servicios se integran nativamente para crear pipelines completos

Siguiente: ¿Dónde almacenamos toda esta data?

Almacenamiento de Datos: Tipos y Servicios GCP



Estructurados

Datos en filas y columnas.

- Bases SQL
- Hojas Excel
- Registros ventas



Semi-estructurados

Organización flexible, sin tablas.

- JSON, XML
- Avro, Logs



No estructurados

Sin formato predefinido.

- Imágenes, Videos
- PDFs, Audios

Soluciones de Almacenamiento en GCP



BigQuery

Data Warehouse

Ideal para: Análisis de datos (OLAP).

- ✓ Serverless & Columnar
- ✓ Petabyte scale
- ✓ SQL nativo



Cloud Storage

Data Lake

Ideal para: Datos crudos y no estructurados.

- ✓ Object storage
- ✓ Multi-class & Global
- ✓ Event triggers



Cloud SQL

Relational DB

Ideal para: Datos transaccionales (OLTP).

- ✓ MySQL/PostgreSQL
- ✓ Managed & High Availability
- ✓ Auto backups



Firestore

NoSQL Document

Ideal para: Apps móviles y web.

- ✓ Real-time & Offline sync
- ✓ Global
- ✓ Document model



Bigtable

NoSQL Wide-column

Ideal para: IoT y analytics masivo.

- ✓ Low latency
- ✓ High throughput
- ✓ HBase API



BigLake

Data Lakehouse

Ideal para: Unificar lake y warehouse.

- ✓ Multi-format
- ✓ Unified governance
- ✓ Open formats

Objetivo: Centralizar, escalar, optimizar y asegurar los datos.

Ventaja GCP: Separación storage/compute para optimizar costos.

⚙️ Procesamiento de Datos en GCP

Servicios para Transformar y Analizar



Cloud Dataflow

Procesamiento Unificado

Capacidades Clave:

- Batch y Streaming unificado
- Auto-scaling automático

Ideal para:

- ✓ ETL/ELT pipelines
- ✓ Agregaciones en tiempo real

SERVERLESS
Con plantillas pre-construidas



Dataproc

Big Data Clusters


Capacidades Clave:

- Clusters administrados
- Soporte Spark, Presto, Hive

Ideal para:

- ✓ Migraciones Hadoop existentes
- ✓ Procesamiento batch pesado

CLUSTER & SERVERLESS
Pago por uso con VMs preemptibles



Data Fusion

Integración Visual ETL

Capacidades Clave:

- Interfaz visual drag-and-drop
- 150+ conectores pre-built

Ideal para:

- ✓ ETL sin código
- ✓ Integraciones rápidas

ENTERPRISE
Gobernanza y Monitoreo

¿Cuál elegir?

⚡ Streaming y Batch

Dataflow



Migración Hadoop/Spark

Dataproc

👁️ ETL Visual (No-Code)

Data Fusion

Todos se integran con **BigQuery** como destino. Dataform para transformaciones SQL.

Visualización y Análisis en GCP

De Datos a Insights Empresariales




Looker

Plataforma BI Empresarial

- ✓ Modelo semántico centralizado (LookML)
- ✓ Dashboards gobernados y self-service
- ✓ Analítica embebible y APIs robustas

Ideal para: Grandes organizaciones con foco en governance.



Looker Studio

Visualización Self-Service

- ✓ Interfaz drag-and-drop intuitiva
- ✓ +800 conectores de datos nativos
- ✓ Colaboración y sharing en tiempo real

Ideal para: Equipos ágiles y reportes rápidos.

Ecosistema de Análisis Extendido



Connected Sheets

BigQuery en Google
Sheets



BigQuery ML

Machine Learning en
SQL



Democratizar Datos

Insights para todos



Insights Accionables


Decisiones informadas

Flujo de integración: BigQuery → Looker / Studio → Business Users


Análisis en tiempo real sobre petabytes de datos

Arquitectura Completa - Stack GCP

Pipeline de Datos de Extremo a Extremo



Ventajas del Stack Completo GCP



Ejemplo: E-commerce

Transacciones (Pub/Sub) → Procesamiento (Dataflow) → Almacén (BigQuery) → Dashboards (Looker)

Resultado: Pipeline completo en horas, no semanas.

Stack unificado: de datos crudos a insights

Arquitectura clave para examen GCP Data Engineer